

## Atsitiktiniai dydžiai ir jų skirstiniai. Bernulio schemos tikimybių aproksimacijos

Prieš pradėdami spręsti 7 užduotį, reikėtų prisiminti Bernulio schemos tikimybių apytikslio skaičiavimo formules, o prieš atliekant 8 ir 9 užduotis, praverstų peržiūrėti paskaitas apie atsitiktinius dydžius ir jų savybes.

Trumpai priminsime kai kurias sąvokas. Bet kokį atsitiktinį dydį  $X$  nusako jo *pasiskirstymo funkcija*  $F(x)$

$$F(x) := P(X \leq x), \quad x \in \mathbb{R}.$$

Žinodami atsitiktinio dydžio pasiskirstymo funkciją, galime nesunkiai rasti patekimo į intervalą  $[a, b)$  tikimybę

$$P(a \leq X < b) = F(b) - F(a). \quad (1)$$

Paprasčiausios atsitiktinio dydžio skaitinės charakteristikos yra vidurkis  $EX$  ir dispersija  $DX = EX^2 - (EX)^2$ . Jų skaičiavimo būdas priklauso nuo atsitiktinio dydžio tipo.

Aptarsime keletą klasikinių atsitiktinių dydžių, kartu nurodydami su jais susijusias *Excel* funkcijas. Skaičiavimams galima naudoti ir analogiškas statistinio paketo *R* arba *Python* bibliotekos *SciPy* funkcijas. Dažnai bus pakankama ir kokia nors "gudresnė" skaičiuoklė, pavyzdžiui:

<https://www.statskingdom.com/index.html>

<https://www.123calculus.com/en>

**Diskretieji atsitiktiniai dydžiai.** Jų reikšmių aibė yra baigtinė arba skaiti. Tokie atsitiktiniai dydžiai  $X$  dažniausiai nusakomi *reikšmių skirstiniu*, nurodant galimas reikšmes  $k$  ir jų tikimybes  $P(X = k)$ . Tada pasiskirstymo funkcija ir vidurkis yra:

$$F(x) = \sum_{k \leq x} P(X = k), \quad EX = \sum_k k P(X = k).$$

Pastebėsime, kad  $F(x+0) = F(x) + P(X = x)$ .

- *Binominis atsitiktinis dydis*  $X \sim \mathcal{B}(n; p)$ . Jo galimos reikšmės  $k = 0, 1, \dots, n$ .

$$\begin{aligned} P(X = k) &= C_n^k p^k (1-p)^{n-k} = \text{binom.dist}(k; n; p; \text{false}), \\ F(x+0) &= \sum_{k \leq x} C_n^k p^k (1-p)^{n-k} = \text{binom.dist}(x; n; p; \text{true}), \\ EX &= np, \quad DX = np(1-p), \end{aligned} \quad (2)$$

čia  $x \leq n$ ,  $0 \leq p \leq 1$ .

- *Geometrinis atsitiktinis dydis*  $X \sim \mathcal{G}(p)$ . Jo galimos reikšmės  $k = 1, 2, \dots$

$$\begin{aligned} P(X = k) &= (1-p)^{k-1} p, \\ F(x+0) &= p \sum_{k \leq x} (1-p)^{k-1} = 1 - (1-p)^{[x]}, \\ EX &= \frac{1}{p}, \quad DX = \frac{1-p}{p^2}, \end{aligned} \quad (3)$$

čia  $x \geq 1$ ,  $0 < p < 1$ .

- *Puasono atsitiktinis dydis*  $X \sim \mathcal{P}(\lambda)$ ,  $\lambda > 0$ . Jo galimos reikšmės  $k = 0, 1, 2, \dots$

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} = \text{poisson.dist}(k; \lambda; \text{false}), \quad (4)$$

$$\begin{aligned} F(x+0) &= e^{-\lambda} \sum_{k \leq x} \frac{\lambda^k}{k!} = \text{poisson.dist}(x; \lambda; \text{true}), \\ EX &= DX = \lambda. \end{aligned} \quad (5)$$

**Absoliučiai tolydūs atsitiktiniai dydžiai.** Tokio atsitiktinio dydžio  $X$  patekimo į intervalą  $[a, b]$  tikimybė yra

$$P(a \leq X \leq b) = \int_a^b p(x) dx, \quad p(x) \geq 0.$$

Funkcija  $p(x)$  vadinama  $X$  tankio funkcija arba tiesiog tankiu. Tada

$$EX = \int_{-\infty}^{\infty} xp(x) dx.$$

Pastebėsime, kad bet kokiam absoliučiai tolydžiam atsitiktiniam dydžiui  $X$  ir realiajam skaičiui  $a$  "taškinė" tikimybė  $P(X = a)$  lygi 0, o tankio funkcija  $p(x)$  tenkina sąlygą

$$\int_{-\infty}^{\infty} p(x) dx = 1. \quad (6)$$

Kita vertus, pasirodo, kad bet kuri neneigiama funkcija  $p(x)$ , tenkinanti pastarąją lygybę, gali būti laikoma kažkokio atsitiktinio dydžio tankiu. Absoliučiai tolydžiojo atsitiktinio dydžio pasiskirstymo funkciją ir tankį sieja lygybės:

$$F(x) = \int_{-\infty}^x p(u) du, \quad F'(x) = p(x). \quad (7)$$

- *Tolygiai pasiskirstęs intervale  $[a, b]$  atsitiktinis dydis  $X \sim \mathcal{T}([a, b])$ .*

$$\begin{aligned} p(x) &= \begin{cases} 0, & \text{jei } x \notin [a, b], \\ \frac{1}{b-a}, & \text{jei } x \in [a, b]. \end{cases} \\ F(x) &= \begin{cases} 0, & \text{jei } x < a, \\ \frac{x-a}{b-a}, & \text{jei } x \in [a, b], \\ 1, & \text{jei } x > b. \end{cases} \\ EX &= \frac{a+b}{2}, \quad DX = \frac{(b-a)^2}{12}. \end{aligned} \quad (8)$$

- *Eksponentinis atsitiktinis dydis  $X \sim \mathcal{E}(\alpha)$ ,  $\alpha > 0$ .*

$$\begin{aligned} p(x) &= \begin{cases} 0, & \text{jei } x < 0, \\ \alpha e^{-\alpha x}, & \text{jei } x \geq 0. \end{cases} \\ F(x) &= \begin{cases} 0, & \text{jei } x < 0, \\ 1 - e^{-\alpha x}, & \text{jei } x \geq 0. \end{cases} \\ EX &= \alpha^{-1}, \quad DX = \alpha^{-2}. \end{aligned} \quad (9)$$

- *Normalusis atsitiktinis dydis  $X \sim \mathcal{N}(a; \sigma^2)$ ,  $a \in \mathbb{R}$ ,  $\sigma > 0$ .*

$$\begin{aligned} p(x) &= \varphi(x; a, \sigma) := \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}} = \text{norm.dist}(x; a; \sigma; \text{false}). \\ F(x) &= \Phi(x; a, \sigma) := \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(u-a)^2}{2\sigma^2}} du = \text{norm.dist}(x; a; \sigma; \text{true}). \\ EX &= a, \quad DX = \sigma^2. \end{aligned} \quad (10)$$

Kai  $a = 0$ ,  $\sigma = 1$ , atsitiktinis dydis  $X$  vadinamas *standartiniu normaliuoju*  $X \sim \mathcal{N}(0; 1)$ . Jo tankio ir pasiskirstymo funkcijos yra

$$\varphi(x) = \varphi(x; 0, 1) = \text{norm.s.dist}(x; \text{false}),$$

$$\Phi(x) = \Phi(x; 0, 1) = \text{norm.s.dist}(x; \text{true}).$$

**Bernulio schemos tikimybių skaičiavimas.** Tegu sėkmės tikimybė viename Bernulio schemos bandyme lygi  $p$ ,  $n$  - bandymų skaičius, o  $S_n$  - atsitiktinis dydis lygus gautų sėkmių skaičiui. Tada  $S_n \sim \mathcal{B}(n; p)$ . Labiausiai tikėtinos  $S_n$  reikšmės yra vienas arba du sveikieji skaičiai iš intervalo  $[np + p - 1, np + p]$ . Nedidelėms  $n$  reikšmėms tikimybės  $P(S_n = k)$  randamos naudojantis (2) formule. Kai eksperimentų daug, skaičiuojant šias tikimybes, galima pasinaudoti apytikslėmis formulėmis:

$$P(S_n = k) \approx \frac{(np)^k}{k!} e^{-np}, \quad (11)$$

$$P(S_n = k) \approx \frac{1}{\sqrt{np(1-p)}} \varphi\left(\frac{k - np}{\sqrt{np(1-p)}}\right), \quad (12)$$

$$P(b < S_n < c) \approx \Phi\left(\frac{c - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{b - np}{\sqrt{np(1-p)}}\right). \quad (13)$$

Apytikslėje lygybėje (11) paklaida neviršija  $np^2$ . Kai  $np^2$  reikšmė yra didelė, geriau naudoti (12) arba (13) lygybes. Formulė (11) vadinama Puasono, o (12) ir (13) Muavro-Laplaso įverčiais.

**1 pavyzdys.** Tegu  $X \sim \mathcal{B}(5; 0, 8)$ . Raskite atsitiktinio dydžio  $Y := X^2 - 1$  pasiskirstymo funkcijos  $F_Y(x)$  reikšmę taške  $x = 2, 7$  ir  $P(1 \leq Y \leq 10)$ .

Pagal apibrėžimą

$$F_Y(2, 7) = P(Y < 2, 7) = P(X^2 < 3, 7) = P(-\sqrt{3, 7} < X < \sqrt{3, 7}) = P(X = 0) + P(X = 1),$$

nes  $X \sim \mathcal{B}(5; 0, 8)$  ir jo galimos reikšmės yra 0, 1, 2, 3, 4, 5. Taigi

$$F_Y(2, 7) = C_5^0 0, 8^0 0, 2^5 + C_5^1 0, 8^1 0, 2^4 = 0, 00672.$$

Žinodami, kad  $X$  reikšmės yra neneigiamos, analogiškai gausime:

$$P(1 \leq Y \leq 10) = P(2 \leq X^2 \leq 11) = P(\sqrt{2} \leq X \leq \sqrt{11}) = P(X = 2) + P(X = 3) = 0, 256.$$

**2 pavyzdys.** Tarkime,  $X$  - normalusis atsitiktinis dydis, t. y.  $X \sim \mathcal{N}(-2; 9)$ , o  $Y$  - atsitiktinai pasirinktas intervalo  $[0, 3]$  skaičius. Raskite atsitiktinio dydžio  $Z := \max(X, Y)$  pasiskirstymo funkcijos  $F_Z(x)$  reikšmę taške  $x = 2$ .

Atsitiktiniai dydžiai yra nepriklausomi, be to  $Y \sim \mathcal{T}([0, 3])$ . Todėl

$$F_Z(2) = P(\max(X, Y) < 2) = P(X < 2)P(Y < 2) = F_X(2)F_Y(2).$$

Panaudoję (8) ir (10) lygybes, gausime  $F_Y(2) = 2/3$  ir

$$F_X(2) = \Phi(2; -2, 3) = \text{norm.dist}(2; -2; 3; \text{true}) \approx 0, 90879.$$

Taigi  $F_Z(2) \approx 0, 60589$ .

**3 pavyzdys.** Atsitiktinio dydžio  $X$  tankio funkcija yra

$$p(x) = \begin{cases} 0, & \text{jei } x \notin [0, \pi], \\ C \sin x, & \text{jei } x \in [0, \pi]. \end{cases}$$

Raskite pasiskirstymo funkcijos  $F(x)$  reikšmę taške  $x = \pi/2$  ir  $P(X > \pi/3)$ .

Pažymėkime  $\mathbf{1}_A(x)$  aibės  $A$  indikatorių

$$\mathbf{1}_A(x) := \begin{cases} 0, & \text{jei } x \notin A, \\ 1, & \text{jei } x \in A. \end{cases}$$

Tada  $p(x) = \mathbf{1}_{[0,\pi]}(x) \cdot C \sin x$ . Pirmiausiai rasime konstantą  $C$ . Pasinaudoję tankio funkcijos savybe (6), gausime

$$\int_{-\infty}^{\infty} p(x) dx = C \int_0^{\pi} \sin x dx = -C \cdot \cos x \Big|_0^{\pi} = 2C = 1.$$

Taigi  $C = 1/2$  ir

$$F(x) = \int_{-\infty}^x p(u) du = \frac{\mathbf{1}_{[0,\pi]}(x)}{2} (1 - \cos x) + \mathbf{1}_{(\pi,\infty)}(x) = \begin{cases} 0, & \text{jei } x < 0, \\ \frac{1}{2}(1 - \cos x), & \text{jei } x \in [0, \pi], \\ 1, & \text{jei } x > \pi. \end{cases}$$

Dabar jau nesunkiai randame:

$$F\left(\frac{\pi}{2}\right) = \frac{1}{2} \left(1 - \cos \frac{\pi}{2}\right) = \frac{1}{2},$$

$$P(X > \pi/3) = 1 - P(X \leq \pi/3) = 1 - (P(X < \pi/3) + P(X = \pi/3)) = 1 - \left(F\left(\frac{\pi}{3}\right) + 0\right) = 1 - \frac{1}{4} = \frac{3}{4},$$

nes  $P(X = a) = 0$  bet kokiam  $a \in \mathbb{R}$  ir absoliučiai tolydziajam dydžiui  $X$ .

**4 pavyzdys.** Informacija perduodama triukšmingu kanalu, kuris vidutiniškai iškraipo 0,1% visų siunčiamų bitų. Siunčiamas 7 kB failas. Koks labiausiai tikėtinas iškraipytų bitų skaičius? Kokia tikimybė, kad iškraipytų bitų skaičius nuo labiausiai tikėtino skirsis ne daugiau kaip 10?

Šiuo atveju sėkmė - gauti iškraipytą bitą. Pagal sąlygą tokios "sėkmės" tikimybė kiekvienu atveju yra  $p = 0,001$ . Mums reikalingas labiausiai tikėtinas "sėkmių" skaičius po  $n = 7 \cdot 1024 \cdot 8 = 57344$  bandymų. Tam, kad jį rastume, nėra būtina skaičiuoti tikimybes  $P(S_{57344} = k)$  visoms 57345 galimoms  $k$  reikšmėms. Kadangi  $np + p = 57,345$ , tai labiausiai tikėtinas iškraipytų bitų skaičius  $k_0$  priklauso intervalui  $[56,345; 57,345]$ , taigi  $k_0 = 57$ . Be to, pritaikę (11) ir (4) lygybes, gausime

$$P(S_{57344} = 57) \approx \text{poisson.dist}(57; 57,344; \text{false}) \approx 0,0527.$$

Atsakymą į antrąjį klausimą sužinosime pasinaudoję (11) ir (5) lygybėmis. Taigi

$$P(47 \leq S_{57344} \leq 67) \approx \text{poisson.dist}(67; 57,344; \text{true}) - \text{poisson.dist}(46; 57,344; \text{true}) \approx 0,83515$$

**5 pavyzdys.** Tikimybė, kad į fakultetą įstojęs moksleivis sėkmingai baigs studijas, lygi 0,8. Kiek mažiausiai reikėtų priimti pirmakursių, kad su tikimybe ne mažesne kaip 90% studijas sėkmingai baigtų ne mažiau kaip 100 studentų?

Tegu  $n \geq 100$  - priimtų pirmakursių skaičius. Sėkmės tikimybė kiekvienam iš jų yra  $p = 0,8$ . Sėkmingai studijas baigusiujų skaičius  $S_n \sim \mathcal{B}(n; p)$ . Reikia rasti mažiausią  $n$ , kuriam

$$P(100 \leq S_n \leq n) \geq 0,9.$$

Pasinaudoję (13) lygybe, gausime

$$P(100 \leq S_n \leq n) \approx \Phi\left(\frac{\sqrt{n}}{2}\right) - \Phi\left(\frac{100 - 0,8n}{0,4\sqrt{n}}\right) \geq 0,9.$$

Kai  $n \geq 100$ , tai

$$\Phi\left(\frac{\sqrt{n}}{2}\right) \geq \Phi(5) \approx 1.$$

Todėl lieka rasti mažiausią nelygybės

$$\Phi\left(\frac{100 - 0,8n}{0,4\sqrt{n}}\right) \leq 0,1 \quad (14)$$

sprendinį. Pirmiausiai rasime standartinio normaliojo skirstinio  $\alpha = 0,1$  lygio kvantilį  $z_{0,1}$ , t.y. lygties

$$\Phi(z_{0,1}) = 0,1$$

sprendinį. Čia praverčia dar viena Excel funkcija:  $z_{0,1} = \text{norm.s.inv}(0,1) \approx -1,28$ . Funkcija  $\Phi(x)$  yra monotoniškai didėjanti. Todėl iš (14) nelygybės gauname, kad

$$\frac{100 - 0,8n}{0,4\sqrt{n}} \leq -1,28.$$

Nesunku patikrinti, kad mažiausias sveikas skaičius, tenkinantis pastarąją nelygybę, yra  $n = 133$ .

Lentelėje pateikiamos skaičiavimams skirtos funkcijos, susijusios su kai kurių klasikinių atsitiktinių dydžių skirstiniais.

Formulė	Excel funkcija	Python scipy.stats funkcija
<i>Binominis atsitiktinis dydis <math>X \sim \mathcal{B}(n; p)</math></i>		
$P(X = k) = C_n^k p^k (1 - p)^{n-k}$	<code>binom.dist(k; n; p; false)</code>	<code>binom.pmf(k=k, n=n, p=p)</code>
$P(X \leq x) = \sum_{k \leq x} C_n^k p^k (1 - p)^{n-k}$	<code>binom.dist(x; n; p; true)</code>	<code>binom.cdf(k=x, n=n, p=p)</code>
<i>Puasono atsitiktinis dydis <math>X \sim \mathcal{P}(\lambda)</math></i>		
$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$	<code>poisson.dist(k; λ; false)</code>	<code>poisson.pmf(k=k, mu=λ)</code>
$P(X \leq x) = e^{-\lambda} \sum_{k \leq x} \frac{\lambda^k}{k!}$	<code>poisson.dist(x; λ; true)</code>	<code>poisson.cdf(k=x, mu=λ)</code>
<i>Normalusis atsitiktinis dydis <math>X \sim \mathcal{N}(a; \sigma^2)</math></i>		
$\varphi(x; a, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-a)^2}{2\sigma^2}}$	<code>norm.dist(x; a; σ; false)</code>	<code>norm.pdf(x=x, loc=a, scale=σ)</code>
$\varphi(x) = \varphi(x; 0, 1)$	<code>norm.s.dist(x; false)</code>	<code>norm.pdf(x=x)</code>
$\Phi(x; a, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(u-a)^2}{2\sigma^2}} du$	<code>norm.dist(x; a; σ; true)</code>	<code>norm.cdf(x=x, loc=a, scale=σ)</code>
$\Phi(x) = \Phi(x; 0, 1)$	<code>norm.s.dist(x; true)</code>	<code>norm.cdf(x=x)</code>
$\alpha$ lygio kvantilis $z_\alpha = \Phi^{-1}(\alpha)$	<code>norm.s.inv(α)</code>	<code>norm.ppf(q=α)</code>
<i>Studento atsitiktinis dydis <math>T_n \sim St(n)</math></i>		
Tankio funkcija $f(x; n) = F'(x; n)$	<code>t.dist(x; n; false)</code>	<code>t.pdf(x=x, df=n)</code>
Pasisk. f-ja $F(x; n) = P(T_n < x)$	<code>t.dist(x; n; true)</code>	<code>t.cdf(x=x, df=n)</code>
$\alpha$ lygio kvantilis $t_\alpha(n) = F^{-1}(\alpha; n)$	<code>t.inv(α; n)</code>	<code>t.ppf(q=α, df=n)</code>
<i><math>\chi^2</math> atsitiktinis dydis <math>\chi_n^2 \sim \chi^2(n)</math></i>		
Tankio funkcija $f(x; n) = F'(x; n)$	<code>chisq.dist(x; n; false)</code>	<code>chi2.pdf(x=x, df=n)</code>
Pasisk. f-ja $F(x; n) = P(\chi_n^2 < x)$	<code>chisq.dist(x; n; true)</code>	<code>chi2.cdf(x=x, df=n)</code>
$\alpha$ lygio kvantilis $\chi_\alpha^2(n) = F^{-1}(\alpha; n)$	<code>chisq.inv(α; n)</code>	<code>chi2.ppf(q=α, df=n)</code>